讲堂 > 数据结构与算法之美 > 文章详情

11 | 排序(上): 为什么插入排序比冒泡排序更受欢迎?

2018-10-15 王争



11 | 排序(上): 为什么插入排序比冒泡排序更受欢迎? 朗读人: 修阳 21'13'' | 8.52M

排序对于任何一个程序员来说,可能都不会陌生。你学的第一个算法,可能就是排序。大部分编程语言中,也都提供了排序函数。在平常的项目中,我们也经常会用到排序。排序非常重要,所以我会花多一点时间来详细讲一讲经典的排序算法。

排序算法太多了,有很多可能你连名字都没听说过,比如猴子排序、睡眠排序、面条排序等。我只讲众多排序算法中的一小撮,也是最经典的、最常用的:冒泡排序、插入排序、选择排序、归并排序、快速排序、计数排序、基数排序、桶排序。我按照时间复杂度把它们分成了三类,分三节课来讲解。



带着问题去学习,是最有效的学习方法。所以按照惯例,我还是先给你出一个思考题: 插入排序和冒泡排序的时间复杂度相同,都是 $O(n^2)$,在实际的软件开发里,为什么我们更倾向于使用插入排序算法而不是冒泡排序算法呢?

你可以先思考一两分钟,带着这个问题,我们开始今天的内容!

如何分析一个"排序算法"?

学习排序算法,我们除了学习它的算法原理、代码实现之外,更重要的是要学会如何评价、分析一个排序算法。那分析一个排序算法,要从哪几个方面入手呢?

排序算法的执行效率

对于排序算法执行效率的分析,我们一般会从这几个方面来衡量:

1. 最好情况、最坏情况、平均情况时间复杂度

我们在分析排序算法的时间复杂度时,要分别给出最好情况、最坏情况、平均情况下的时间复杂度。除此之外,你还要说出最好、最坏时间复杂度对应的要排序的原始数据是什么样的。

为什么要区分这三种时间复杂度呢?第一,有些排序算法会区分,为了好对比,所以我们最好都做一下区分。第二,对于要排序的数据,有的接近有序,有的完全无序。有序度不同的数据,对于排序的执行时间肯定是有影响的,我们要知道排序算法在不同数据下的性能表现。

2. 时间复杂度的系数、常数、低阶

我们知道,时间复杂度反应的是数据规模 n 很大的时候的一个增长趋势,所以它表示的时候会忽略系数、常数、低阶。但是实际的软件开发中,我们排序的可能是 10 个、100 个、1000 个这样规模很小的数据,所以,在对同一阶时间复杂度的排序算法性能对比的时候,我们就要把系数、常数、低阶也考虑进来。

3. 比较次数和交换(或移动)次数

这一节和下一节讲的都是基于比较的排序算法。基于比较的排序算法的执行过程,会涉及两种操作,一种是元素比较大小,另一种是元素交换或移动。所以,如果我们在分析排序算法的执行效率的时候,应该把比较次数和交换(或移动)次数也考虑进去。

排序算法的内存消耗

我们前面讲过,算法的内存消耗可以通过空间复杂度来衡量,排序算法也不例外。不过,针对排序算法的空间复杂度,我们还引入了一个新的概念,原地排序(Sorted in place)。原地排序算法,就是特指空间复杂度是 O(1) 的排序算法。我们今天讲的三种排序算法,都是原地排序算法。

排序算法的稳定性

仅仅用执行效率和内存消耗来衡量排序算法的好坏是不够的。针对排序算法,我们还有一个重要的 度量指标,稳定性。这个概念是说,如果待排序的序列中存在值相等的元素,经过排序之后,相等 元素之间原有的先后顺序不变。

我通过一个例子来解释一下。比如我们有一组数据 2, 9, 3, 4, 8, 3, 按照大小排序之后就是 2, 3, 3, 4, 8, 9。

这组数据里有两个 3。经过某种排序算法排序之后,如果两个 3 的前后顺序没有改变,那我们就把 这种排序算法叫作稳定的排序算法;如果前后顺序发生变化,那对应的排序算法就叫作不稳定的排 序算法。

你可能要问了,两个 **3** 哪个在前,哪个在后有什么关系啊,稳不稳定又有什么关系呢?为什么要考察排序算法的稳定性呢?

很多数据结构和算法课程,在讲排序的时候,都是用整数来举例,但在真正软件开发中,我们要排序的往往不是单纯的整数,而是一组对象,我们需要按照对象的某个 key 来排序。

比如说,我们现在要给电商交易系统中的"订单"排序。订单有两个属性,一个是下单时间,另一个是订单金额。如果我们现在有 10 万条订单数据,我们希望按照金额从小到大对订单数据排序。对于金额相同的订单,我们希望按照下单时间从早到晚有序。对于这样一个排序需求,我们怎么来做呢?

最先想到的方法是:我们先按照金额对订单数据进行排序,然后,再遍历排序之后的订单数据,对于每个金额相同的小区间再按照下单时间排序。这种排序思路理解起来不难,但是实现起来会很复杂。

借助稳定排序算法,这个问题可以非常简洁地解决。解决思路是这样的:我们先按照下单时间给订单排序,注意是按照下单时间,不是金额。排序完成之后,我们用稳定排序算法,按照订单金额重新排序。两遍排序之后,我们得到的订单数据就是按照金额从小到大排序,金额相同的订单按照下单时间从早到晚排序的。为什么呢?

稳定排序算法可以保持金额相同的两个对象,在排序之后的前后顺序不变。第一次排序之后,所有的订单按照下单时间从早到晚有序了。在第二次排序中,我们用的是稳定的排序算法,所以经过第二次排序之后,相同金额的订单仍然保持下单时间从早到晚有序。

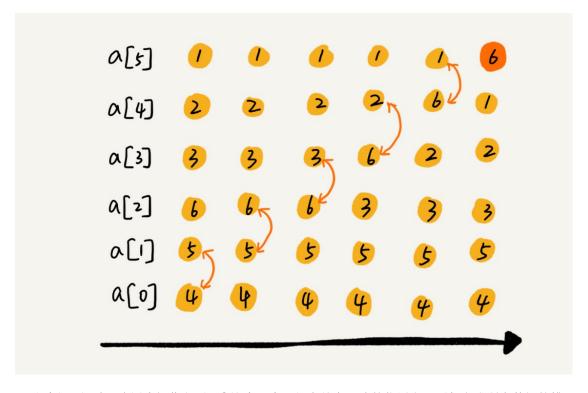
按下单时间有序				按金额重新排序			
LD	降时间	额		ID	净时间	鍃	
1	2018-9-3 15:06:07	50		1	2018-9-3 16:08:10	30	
2	2018-9-3 16:08:10	30		2	2018-9-3 20:23:31	30	
3	2018-9-3 18:01:33	40	→	3	2018-9-3 22:15:13	30	
4	2018-9-3 20:23:31	30		4	2018-9-3 18:01:33	40	
5	2018-9-3 22:15:13	30		5	2018-9-3 15:06:07	50	
6	2018-9-4 05:07:33	60		6	2018-9-4 05:07:33	60	

冒泡排序(Bubble Sort)

我们从冒泡排序开始,学习今天的三种排序算法。

冒泡排序只会操作相邻的两个数据。每次冒泡操作都会对相邻的两个元素进行比较,看是否满足大小关系要求。如果不满足就让它俩互换。一次冒泡会让至少一个元素移动到它应该在的位置,重复n次,就完成了n个数据的排序工作。

我用一个例子,带你看下冒泡排序的整个过程。我们要对一组数据 **4**, **5**, **6**, **3**, **2**, **1**, 从小到到大进行排序。第一次冒泡操作的详细过程就是这样:



可以看出,经过一次冒泡操作之后,6这个元素已经存储在正确的位置上。要想完成所有数据的排

冒泡次数	粒后的结果
初始状态	4 5 6 3 2 1
第1次置包	4 5 3 2 1 6
第2次冒泡	432156
第3次冒泡	3 2 1 4 5 6
第4次冒泡	2 1 3 4 5 6
第5次冒泡	1 2 3 4 5 6
第6次冒泡	1 2 3 4 5 6

实际上,刚讲的冒泡过程还可以优化。当某次冒泡操作已经没有数据交换时,说明已经达到完全有序,不用再继续执行后续的冒泡操作。我这里还有另外一个例子,这里面给 6 个元素排序,只需要4次冒泡操作就可以了。

冒泡火数	验后结果	是否数据交换
初始状态	354126	_
第次電泡	341256	有
第2次冒泡	312456	有
第3次冒泡	123456	有
第4次冒泡	123456	无,结束排序操作

冒泡排序算法的原理比较容易理解,具体的代码我贴到下面,你可以结合着代码来看我前面讲的原理。

```
■ 复制代码
 1 // 冒泡排序, a 表示数组, n 表示数组大小
 2 public void bubbleSort(int[] a, int n) {
   if (n <= 1) return;
5 for (int i = 0; i < n; ++i) {
     // 提前退出冒泡循环的标志位
     boolean flag = false;
    for (int j = 0; j < n - i - 1; ++j) {
     if (a[j] > a[j+1]) { // 交换
        int tmp = a[j];
        a[j] = a[j+1];
       a[j+1] = tmp;
       flag = true; // 表示有数据交换
14 }
    }
    if (!flag) break; // 没有数据交换,提前退出
17 }
18 }
```

现在,结合刚才我分析排序算法的三个方面,我有三个问题要问你。

第一,冒泡排序是原地排序算法吗?

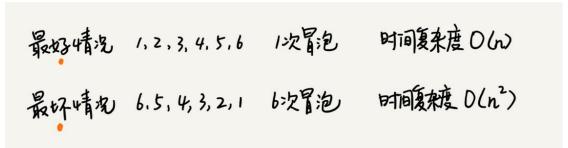
冒泡的过程只涉及相邻数据的交换操作,只需要常量级的临时空间,所以它的空间复杂度为 **O(1)**,是一个原地排序算法。

第二,冒泡排序是稳定的排序算法吗?

在冒泡排序中,只有交换才可以改变两个元素的前后顺序。为了保证冒泡排序算法的稳定性,当有相邻的两个元素大小相等的时候,我们不做交换,相同大小的数据在排序前后不会改变顺序,所以冒泡排序是稳定的排序算法。

第三,冒泡排序的时间复杂度是多少?

最好情况下,要排序的数据已经是有序的了,我们只需要进行一次冒泡操作,就可以结束了,所以最好情况时间复杂度是 O(n)。而最坏的情况是,要排序的数据刚好是倒序排列的,我们需要进行 n次冒泡操作,所以最坏情况时间复杂度为 $O(n^2)$ 。



最好、最坏情况下的时间复杂度很容易分析,那平均情况下的时间复杂是多少呢?我们前面讲过, 平均时间复杂度就是加权平均期望时间复杂度,分析的时候要结合概率论的知识。

对于包含 n 个数据的数组,这 n 个数据就有 n! 种排列方式。不同的排列方式,冒泡排序执行的时间肯定是不同的。比如我们前面举的那两个例子,其中一个要进行 6 次冒泡,而另一个只需要 4 次。如果用概率论方法定量分析平均时间复杂度,涉及的数学推理和计算就会很复杂。我这里还有一种

思路,通过"有序度"和"逆序度"这两个概念来进行分析。

有序度是数组中具有有序关系的元素对的个数。有序元素对用数学表达式表示就是这样:

1 有序元素对: a[i] <= a[j], 如果 i < j。

2,4,3,1,5,6 这组数据的有序度为11, 因其有序记案对为11个,分别是:

同理,对于一个倒序排列的数组,比如 6, 5, 4, 3, 2, 1, 有序度是 0; 对于一个完全有序的数组,比如 1, 2, 3, 4, 5, 6, 有序度就是 $n^*(n-1)/2$,也就是 15。我们把这种完全有序的数组的有序度叫作满有序度。

逆序度的定义正好跟有序度相反(默认从小到大为有序),我想你应该已经想到了。关于逆序度,我就不举例子讲了。你可以对照我讲的有序度的例子自己看下。

1 逆序元素对: a[i] > a[j], 如果 i < j。

关于这三个概念,我们还可以得到一个公式:逆序度=满有序度-有序度。我们排序的过程就是一种增加有序度,减少逆序度的过程,最后达到满有序度,就说明排序完成了。

我还是拿前面举的那个冒泡排序的例子来说明。要排序的数组的初始状态是 4, 5, 6, 3, 2, 1, 其中,有序元素对有 (4, 5) (4, 6)(5, 6), 所以有序度是 3。 n=6,所以排序完成之后终态的满有序度为 n*(n-1)/2=15。

冒泡次数	冒泡后结果	有度
初始状态	4 5 6 3 2 1	3
第次冒泡	4 5 3 2 1 6	6
第2次冒泡	4 3 2 1 5 6	9
第3次冒泡	3 2 1 4 5 b	12
第4次冒泡	2 1 3 4 5 6	14
第5次冒泡	123456	15

冒泡排序包含两个操作原子,比较和交换。每交换一次,有序度就加 1。不管算法怎么改进,交换次数总是确定的,即为逆序度,也就是**n*(n-1)/2**-初始有序度。此例中就是 **15-3=12**,要进行 **12** 次交换操作。

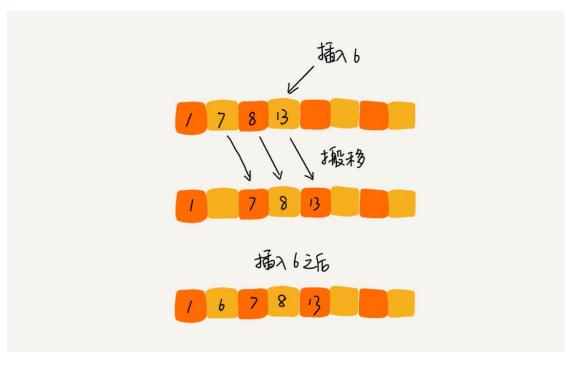
对于包含 n 个数据的数组进行冒泡排序,平均交换次数是多少呢?最坏情况下,初始状态的有序度是 n*(n-1)/2 次交换。最好情况下,初始状态的有序度是 n*(n-1)/2,就不需要进行交换。我们可以取个中间值 n*(n-1)/4,来表示初始有序度既不是很高也不是很低的平均情况。

换句话说,平均情况下,需要 $n^*(n-1)/4$ 次交换操作,比较操作肯定要比交换操作多,而复杂度的上限是 $O(n^2)$,所以平均情况下的时间复杂度就是 $O(n^2)$ 。

这个平均时间复杂度推导过程其实并不严格,但是很多时候很实用,毕竟概率论的定量分析太复杂,不太好用。等我们讲到快排的时候,我还会再次用这种"不严格"的方法来分析平均时间复杂度。

插入排序(Insertion Sort)

我们先来看一个问题。一个有序的数组,我们往里面添加一个新的数据后,如何继续保持数据有序呢?很简单,我们只要遍历数组,找到数据应该插入的位置将其插入即可。

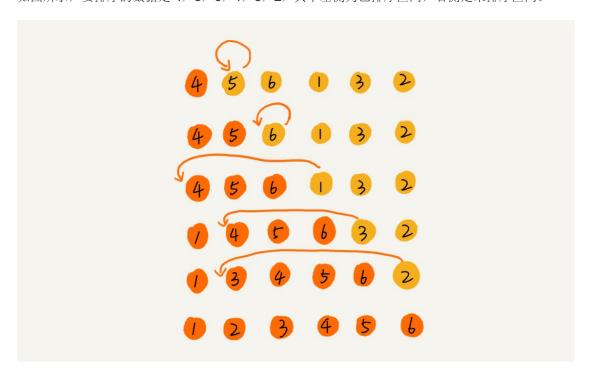


这是一个动态排序的过程,即动态地往有序集合中添加数据,我们可以通过这种方法保持集合中的数据一直有序。而对于一组静态数据,我们也可以借鉴上面讲的插入方法,来进行排序,于是就有了插入排序算法。

那插入排序具体是如何借助上面的思想来实现排序的呢?

首先,我们将数组中的数据分为两个区间,已排序区间和未排序区间。初始已排序区间只有一个元素,就是数组的第一个元素。插入算法的核心思想是取未排序区间中的元素,在已排序区间中找到合适的插入位置将其插入,并保证已排序区间数据一直有序。重复这个过程,直到未排序区间中元素为空,算法结束。

如图所示,要排序的数据是4,5,6,1,3,2,其中左侧为已排序区间,右侧是未排序区间。

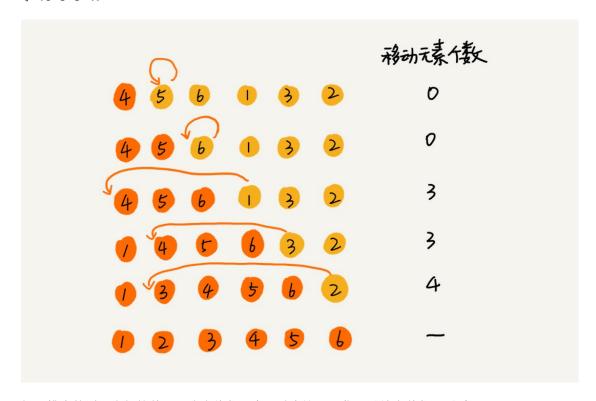


插入排序也包含两种操作,一种是元素的比较,一种是元素的移动。当我们需要将一个数据 a 插入

到已排序区间时,需要拿 a 与已排序区间的元素依次比较大小,找到合适的插入位置。找到插入点之后,我们还需要将插入点之后的元素顺序往后移动一位,这样才能腾出位置给元素 a 插入。

对于不同的查找插入点方法(从头到尾、从尾到头),元素的比较次数是有区别的。但对于一个给 定的初始序列,移动操作的次数总是固定的,就等于逆序度。

为什么说移动次数就等于逆序度呢? 我拿刚才的例子画了一个图表,你一看就明白了。满有序度是 n*(n-1)/2=15, 初始序列的有序度是 5, 所以逆序度是 10。插入排序中,数据移动的个数总和也等于 10=3+3+4。



插入排序的原理也很简单吧? 我也将代码实现贴在这里, 你可以结合着代码再看下。

```
■复制代码
 1 // 插入排序, a 表示数组, n 表示数组大小
 2 public void insertionSort(int[] a, int n) {
 3 if (n <= 1) return;</pre>
 5 for (int i = 1; i < n; ++i) {
     int value = a[i];
     int j = i - 1;
     // 查找插入的位置
     for (; j >= 0; --j) {
     if (a[j] > value) {
        a[j+1] = a[j]; // 数据移动
      } else {
        break;
      }
     }
     a[j+1] = value; // 插入数据
17 }
18 }
```

现在,我们来看点稍微复杂的东西。我这里还是有三个问题要问你。

第一,插入排序是原地排序算法吗?

从实现过程可以很明显地看出,插入排序算法的运行并不需要额外的存储空间,所以空间复杂度是**O(1)**,也就是说,这是一个原地排序算法。

第二,插入排序是稳定的排序算法吗?

在插入排序中,对于值相同的元素,我们可以选择将后面出现的元素,插入到前面出现元素的后面,这样就可以保持原有的前后顺序不变,所以插入排序是稳定的排序算法。

第三,插入排序的时间复杂度是多少?

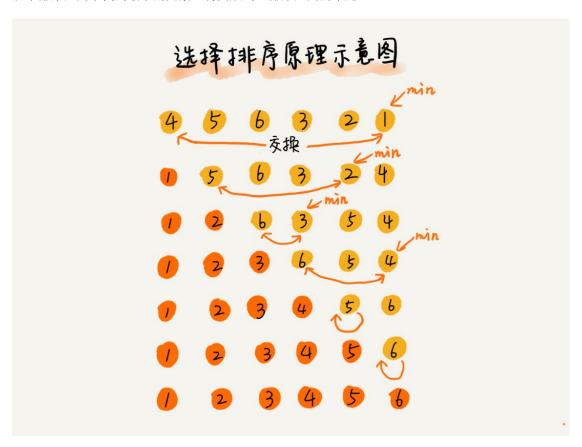
如果要排序的数据已经是有序的,我们并不需要搬移任何数据。如果我们从尾到头在有序数据组里 面查找插入位置,每次只需要比较一个数据就能确定插入的位置。所以这种情况下,最好是时间复 杂度为 **O(n)**。注意,这里是从尾到头遍历已经有序的数据。

如果数组是倒序的,每次插入都相当于在数组的第一个位置插入新的数据,所以需要移动大量的数据,所以最坏情况时间复杂度为 $O(n^2)$ 。

还记得我们在数组中插入一个数据的平均时间复杂度是多少吗?没错,是O(n)。所以,对于插入排序来说,每次插入操作都相当于在数组中插入一个数据,循环执行n次插入操作,所以平均时间复杂度为 $O(n^2)$ 。

选择排序(Selection Sort)

选择排序算法的实现思路有点类似插入排序,也分已排序区间和未排序区间。但是选择排序每次会从未排序区间中找到最小的元素,将其放到已排序区间的末尾。



照例,也有三个问题需要你思考,不过前面两种排序算法我已经分析得很详细了,这里就直接公布

首先,选择排序空间复杂度为 O(1),是一种原地排序算法。选择排序的最好情况时间复杂度、最坏情况和平均情况时间复杂度都为 $O(n^2)$ 。你可以自己来分析看看。

那选择排序是稳定的排序算法吗?这个问题我着重来说一下。

答案是否定的,选择排序是一种不稳定的排序算法。从我前面画的那张图中,你可以看出来,选择排序每次都要找剩余未排序元素中的最小值,并和前面的元素交换位置,这样破坏了稳定性。

比如 5, 8, 5, 2, 9 这样一组数据,使用选择排序算法来排序的话,第一次找到最小元素 2, 与第一个 5 交换位置,那第一个 5 和中间的 5 顺序就变了,所以就不稳定了。正是因此,相对于冒泡排序和插入排序,选择排序就稍微逊色了。

解答开篇

基本的知识都讲完了,我们来看开篇的问题: 冒泡排序和插入排序的时间复杂度都是 **O**(n²), 都是原地排序算法,为什么插入排序要比冒泡排序更受欢迎呢?

我们前面分析冒泡排序和插入排序的时候讲到,冒泡排序不管怎么优化,元素交换的次数是一个固定值,是原始数据的逆序度。插入排序是同样的,不管怎么优化,元素移动的次数也等于原始数据的逆序度。

但是,从代码实现上来看,冒泡排序的数据交换要比插入排序的数据移动要复杂,冒泡排序需要 **3** 个赋值操作,而插入排序只需要 **1** 个。我们来看这段操作:

```
1 冒泡排序中数据的交换操作:
2 if (a[j] > a[j+1]) { // 交换
3 int tmp = a[j];
4 a[j] = a[j+1];
5 a[j+1] = tmp;
6 flag = true;
7 }
8
9 插入排序中数据的移动操作:
10 if (a[j] > value) {
11 a[j+1] = a[j]; // 数据移动
12 } else {
13 break;
14 }
```

我们把执行一个赋值语句的时间粗略地计为单位时间(unit_time),然后分别用冒泡排序和插入排序对同一个逆序度是 K 的数组进行排序。用冒泡排序,需要 K 次交换操作,每次需要 3 个赋值语句,所以交换操作总耗时就是 3*K 单位时间。而插入排序中数据移动操作只需要 K 个单位时间。

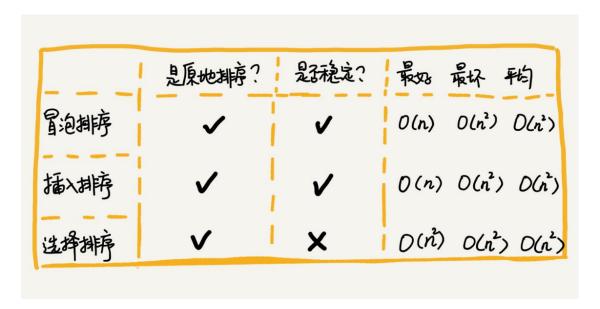
这个只是我们非常理论的分析,为了实验,针对上面的冒泡排序和插入排序的 Java 代码,我写了一个性能对比测试程序,随机生成 10000 个数组,每个数组中包含 200 个数据,然后在我的机器上分别用冒泡和插入排序算法来排序,冒泡排序算法大约 700ms 才能执行完成,而插入排序只需要100ms 左右就能搞定!

所以,虽然冒泡排序和插入排序在时间复杂度上是一样的,都是 **O(n²)**,但是如果我们希望把性能 优化做到极致,那肯定首选插入排序。插入排序的算法思路也有很大的优化空间,我们只是讲了最

基础的一种。如果你对插入排序的优化感兴趣,可以自行学习一下希尔排序。

内容小结

要想分析、评价一个排序算法,需要从执行效率、内存消耗和稳定性三个方面来看。因此,这一节,我带你分析了三种时间复杂度是 $O(n^2)$ 的排序算法,冒泡排序、插入排序、选择排序。你需要重点掌握的是它们的分析方法。



这三种时间复杂度为 $O(n^2)$ 的排序算法中,冒泡排序、选择排序,可能就纯粹停留在理论的层面了,学习的目的也只是为了开拓思维,实际开发中应用并不多,但是插入排序还是挺有用的。后面讲排序优化的时候,我会讲到,有些编程语言中的排序函数的实现原理会用到插入排序算法。

今天讲的这三种排序算法,实现代码都非常简单,对于小规模数据的排序,用起来非常高效。但是在大规模数据排序的时候,这个时间复杂度还是稍微有点高,所以我们更倾向于用下一节要讲的时间复杂度为 O(nlogn) 的排序算法。

课后思考

我们讲过,特定算法是依赖特定的数据结构的。我们今天讲的几种排序算法,都是基于数组实现的。如果数据存储在链表中,这三种排序算法还能工作吗?如果能,那相应的时间、空间复杂度又是多少呢?

欢迎留言和我分享,我会第一时间给你反馈。

我已将本节内容相关的详细代码更新到 Github,戳此即可查看。



版权归极客邦科技所有, 未经许可不得转载

写留言

------通过留言可与作者互动 --